

Análisis e Interpretación de Datos

MÁSTER UNIVERSITARIO EN ANÁLISIS Y VISUALIZACIÓN DE DATOS
MASIVOS / VISUAL ANALYTICS AND BIG DATA

Miller Janny Ariza Garzón

Tema 5. Probabilidad Condicional y Variables Aleatorias II

Tabla de contenido

□ Tema 5: Probabilidad condicional y variables aleatorias

- Variable aleatoria.
- Modelos discretos.
- Modelos continuos.

Contenido

Probabilidad condicional y variables aleatorias

Probabilidad condicional e independencia

$$P(A \text{ sabiendo que ha ocurrido } B) = P(A|B)$$

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

sucesos independientes
 $P(A|B)=P(A)$


Distribución Binomial

$$X \sim Bi(n, p)$$

$$P(X = k) = \binom{n}{k} p^k q^{n-k}$$

Distribución Normal

$$X \sim N(\mu, \sigma)$$



Variables aleatorias

2.

Discretas

(un dado, una moneda etc.)

$$P(X = x_i)$$

$$F(x_i) = P(X \leq x_i)$$

$$E(X) = \sum x_i p_i$$

$$\sigma_x^2 = \sum (x_i - E(X))^2 p_i$$

1.

Continuas

(peso, tiempo etc.)

$$P(a < x < b) = \int_a^b f(x) dx$$

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

$$E(X) = \int x f(x) dx$$

$$V(X) = \int (x - \mu)^2 f(x) dx$$

Variable aleatoria

Se llama **variable aleatoria** a toda función que asocia a cada elemento del espacio muestral, un número real.

$$X: \Omega \rightarrow R$$

Se utilizan letras mayúsculas para designar las variables aleatoria: X , Y , Z ; y sus respectivas letras minúsculas para los valores concretos de las mismas: x , y , z .

Variable aleatoria discreta Es la que solo puede tomar un numerable o infinito numerable de valores.

$$x \in \{x_1, x_2, \dots, x_n\} \text{ o } x \in \{x_1, x_2, \dots\}$$

Variable aleatoria continua Es aquella que puede tomar infinitos valores dentro de un intervalo de números reales

$$x \in \{x: a < x < b; a, b \in R\}$$

Variable aleatoria

Ej. Exp: Lanzamiento de 2 monedas

$X(s)$: Número de CARAS

$$\Omega = \{CC, CS, SC, SS\}$$

$$X: \Omega \rightarrow R$$

$$s \in \Omega \rightarrow X(s)$$

$$CC \rightarrow 2$$

$$CS \rightarrow 1$$

$$SC \rightarrow 1$$

$$SS \rightarrow 0$$

ISS-UNIO

Función de probabilidad

$$f(x): R \rightarrow [0,1]$$

Para v.a. discretas

Función másica de probabilidad

$$f(x_i) = P(X = x_i); i = 1, 2, 3, \dots$$

- i. $P(X = x) \geq 0$
- ii. $\sum_x P(X = x) = 1$

Probabilidades se hallan mediante:

$$\sum$$

Para v.a. continuas

Función de densidad

$$f(x)$$

- i. $f(x) \geq 0$
- ii. $\int_{-\infty}^{\infty} f(x) dx = 1$

Probabilidades se hallan mediante:

$$\int$$

Función de probabilidad

Para v.a. discretas

Función másica de probabilidad

$$f(x_i) = P(X = x_i); i = 1, 2, 3, \dots$$

$$\left. \begin{array}{l} P(a < X < b) \\ P(a \leq X \leq b) \\ P(a \leq X < b) \\ P(a < X \leq b) \end{array} \right\} \text{ Pueden ser diferentes}$$


- $P(X = a) \in [0, 1]$

Para v.a. continuas

Función de densidad

$$f(x)$$

$$P(a < X < b) = \int_a^b f(x) dx$$



$$\begin{aligned} P(a < X < b) &= \\ P(a \leq X \leq b) &= \\ P(a \leq X < b) &= \\ P(a < X \leq b) &= \end{aligned}$$

- $P(X = a) = 0$

Función de probabilidad

Ej. v.a. discretas

X = “el número de mujeres (M) que una pareja puede tener si tienen dos hijos”

$$\Omega = \{HH, HM, MH, MM\}$$

X	0	1	2
$P(X = x)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

- $P(X \leq 1) = \frac{1}{2} + \frac{1}{4} = 0.75$
- $P(X < 1) = \frac{1}{4}$
- $P(X = 1) = \frac{1}{2}$

Ej. v.a. continuas

X = Tiempo de espera antes de atención en una llamada a sanidad. (en minutos, máximo de 2 minutos)

$$f(x) = \begin{cases} \frac{x}{2} & \text{si } 0 \leq x \leq 2 \\ 0 & \text{e.o.c.} \end{cases}$$

$$\int_{-\infty}^{\infty} \frac{x}{2} dx = \int_0^2 \frac{x}{2} dx = \frac{x^2}{4} \Big|_0^2 = 1$$

- $P(X < 1) = P(X \leq 1) = \int_0^1 f(x) dx = \frac{1}{4}$
- $P(X = 1) = 0$

Función acumulada de probabilidad

Se define para todos los reales $-\infty < x < \infty$.

$$F(x) = P(X \leq x)$$

Toda probabilidad se puede hallar en función de $F(x)$

Ej. v.a. discretas

$$F(a) = P(X \leq a) = \sum_{x \leq a} P(X = x)$$

Ej. v.a. continuas

$$F(a) = P(X \leq a) = \int_{-\infty}^a f(x) dx$$

A la Función acumulada de probabilidad también se le llama Función de distribución


Función acumulada de probabilidad

Ej. v.a. discretas

X = “el número de mujeres (M) que una pareja puede tener si tienen dos hijos”

X	0	1	2
$P(X = x)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

$$F(x) = \begin{cases} 0, & \text{for } x < 0 \\ 0.25 & \text{for } 0 \leq x < 1 \\ 0.75 & \text{for } 1 \leq x < 2 \\ 1 & \text{for } x \geq 2. \end{cases}$$




Ej. v.a. continuas

X = Tiempo de espera antes de atención en una llamada a sanidad. (en minutos, máximo de 2 minutos)

$$f(x) = \begin{cases} \frac{x}{2} & \text{si } 0 \leq x \leq 2 \\ 0 & \text{e.o.c.} \end{cases}$$

$$F(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{x^2}{4} & \text{si } 0 \leq x \leq 2 \\ 1 & \text{si } x > 2 \end{cases}$$



Función acumulada de probabilidad

Ej. v.a. discretas

X = “el número de mujeres (M) que una pareja puede tener si tienen dos hijos”

X	0	1	2
$P(X = x)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

$$F(x) = \begin{cases} 0, & \text{for } x < 0 \\ 0.25 & \text{for } 0 \leq x < 1 \\ 0.75 & \text{for } 1 \leq x < 2 \\ 1 & \text{for } x \geq 2. \end{cases}$$

- $P(X \leq 1) = F(1) = 0.75$
- $P(X < 1) = F(0) = 0.25$
- $P(X = 1) = F(1) - F(0) = 0.75 - 0.25 = 0.5$

Ej. v.a. continuas

X = Tiempo de espera antes de atención en una llamada a sanidad. (en minutos, máximo de 2 minutos)

$$f(x) = \begin{cases} \frac{x}{2} & \text{si } 0 \leq x \leq 2 \\ 0 & \text{e.o.c.} \end{cases}$$

$$F(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{x^2}{4} & \text{si } 0 \leq x \leq 2 \\ 1 & \text{si } x > 2 \end{cases}$$

- $P(X < 1) = F(1) = \frac{1}{4} = 0.25$
- $P(0.5 < X < 1.5) = F(1.5) - F(0.5) = \frac{1.5^2}{4} - \frac{0.5^2}{4} = 0.5$

$$P(a \leq X \leq b) = F(b) - F(a)$$

Momentos de una variable aleatoria

$E(X) = \mu_X \longrightarrow$ Esperanza o valor esperado. Valor medio

$V(X) = \sigma_X^2 = E(X - \mu_X)^2 \longrightarrow$ Varianza

Ej. v.a. discretas

$$E(X) = \sum_x x * P(X = x)$$

$$V(X) = \sum_x (x - \mu_X)^2 * P(X = x)$$

Ej. v.a. continuas

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

$$V(X) = \int_{-\infty}^{\infty} (x - \mu_X)^2 f(x) dx$$

Momentos de una variable aleatoria

Ej. v.a. discretas

X = “el número de mujeres (M) que una pareja puede tener si tienen dos hijos”

X	0	1	2
$P(X = x)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

$$E(X) = 0 * \frac{1}{4} + 1 * \frac{1}{2} + 2 * \frac{1}{4} = 1$$

$$V(X) = (0 - 1)^2 * \frac{1}{4} + (1 - 1)^2 * \frac{1}{2} + (2 - 1)^2 * \frac{1}{4} = 0.5$$

$$\sigma = 0.707$$

Ej. v.a. continuas

X = Tiempo de espera antes de atención en una llamada a sanidad. (en minutos, máximo de 2 minutos)

$$f(x) = \begin{cases} \frac{x}{2} & \text{si } 0 \leq x \leq 2 \\ 0 & \text{e.o.c.} \end{cases}$$

$$E(X) = \int_0^2 x \left(\frac{x}{2}\right) dx = \left[\frac{x^3}{6}\right]_0^2 = \frac{8}{6} = 4/3$$

$$V(X) = \int_0^2 \left(x - \frac{4}{3}\right)^2 \left(\frac{x}{2}\right) dx = \int_0^2 x^2 \left(\frac{x}{2}\right) dx - \left(\frac{4}{3}\right)^2 = 2 - \frac{16}{9} = 2/9$$

$$\sigma = 0.471$$

Momentos de una variable aleatoria

Propiedades:

- $E(k) = k$
- $E(k + x) = k + E(x)$
- $E(kx) = kE(x)$
- $E(ax + b) = aE(x) + b$
- $V(k) = 0$
- $V(k + x) = V(x)$
- $V(kx) = k^2V(x)$
- $V(ax + b) = a^2V(x)$

EE-UTM

Si X y Y son dos variables aleatorias:

- $E(X + Y) = E(X) + E(Y)$
- $V(X \pm Y) = V(X) + V(Y) \pm 2Cov(X, Y) = V(X) + V(Y) \pm 2\rho_{XY}\sigma_X\sigma_Y$
- Si X y Y son independientes: $V(X \pm Y) = V(X) + V(Y)$



Correlación de X y Y

Momentos de una variable aleatoria

Ejemplo: Si quieres estudiar en EEUU (e incluso a nivel laboral) te pueden exigir realizar la prueba conocida como SAT, la cual a su vez consta de varias partes.

Aptitud matemática

$$E(X) = 419$$

$$\sigma_X = 105$$

Aptitud lingüística

$$E(Y) = 407$$

$$\sigma_Y = 91$$

$$\rho_{XY} = 0.81$$

¿Cuál es el valor esperado y la varianza para las dos pruebas en conjunto?

$$E(X + Y) = 419 + 407 = 826$$


$$V(X + Y) = 105^2 + 91^2 + 2 * 0.81 * 105 * 91 = 34781.1$$

Ejemplos distribuciones de probabilidad

Ej. v.a. discretas

Distribución binomial

$$X \sim B(n, p)$$




X: Número de éxitos en n ensayos independientes (o una muestra de tamaño n).

$$X = 0, 1, \dots, n$$

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$\mu = np$$

$$\sigma^2 = np(1 - p)$$




Ej. v.a. continuas

Distribución normal

$$X \sim N(\mu, \sigma)$$


$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$



- La forma acampanada de la función de densidad se llama campana de Gauss.

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

Z es el número de desviaciones estándar en que se aleja un valor x de su respectiva media.



Ejemplos distribuciones de probabilidad

Ej. v.a. discretas

Distribución binomial

X = Número de caras al lanzar una moneda en 6 lanzamientos

$$X \sim Bi(6, \frac{1}{2})$$

$$P(X = 2) = \binom{6}{2} \times 0,5^2 \times 0,5^4 = 15 \times 0,25 \times 0,0625 = 0,234$$

$$E(X) = 2 \times \frac{1}{2} = 1 \text{ cara} \quad \text{y} \quad V(X) = 2 \times \frac{1}{2} \times \frac{1}{2} = 1/2$$

$$\sigma = 0.70$$

Ej. v.a. continuas

Distribución normal


Una empresa de telecomunicaciones ha determinado, que la transmisión de datos **promedio es de 175 segundos** con una **desviación estándar de 25 segundos** y una **distribución normal** definida. Con el fin de analizar la demanda de servicios y maximizar la oferta de los mismos se desea obtener la probabilidad de que los tiempos de comunicación oscilen entre 125 y 175 segundos

x = tiempo de transmisión en segundos

$\mu = 175$ seg. (media)

$\sigma = 20$ seg. (desviación estándar)

$$P(125 < X < 175) = F(175) - F(125)$$



Ejemplos distribuciones de probabilidad

Ej. v.a. discretas

Distribución binomial en R

- `dbinom(x, size, prob)` Probabilidad puntual
- `pbinom(x, size, prob)` Probabilidad acumulada
- `qbinom(p, size, prob)` Quantile
- `rbinom(n, size, prob)` Números aleatorios

- **x** is a vector of numbers.
- **p** is a vector of probabilities.
- **n** is number of observations.
- **size** is the number of trials.
- **prob** is the probability of success of each trial.

Ej. v.a. continuas

Distribución normal en R

- `dnorm(x, mean, sd)` Valor en la función de densidad
- `pnorm(x, mean, sd)` Probabilidad acumulada
- `qnorm(p, mean, sd)` Quantile
- `rnorm(n, mean, sd)` Números aleatorios

- **x** is a vector of numbers.
- **p** is a vector of probabilities.
- **n** is number of observations(sample size).
- **mean** is the mean value of the sample data. It's default value is zero.
- **sd** is the standard deviation. It's default value is 1

Tema 6: Distribución en el muestreo

- Distribución en el muestreo del conteo y la proporción muestral
- Central del Límite y distribución de la media muestral
- Aplicabilidad del Teorema Central del Límite en ámbitos Big Data
- Estimación puntual vs estimación por intervalos
- Propiedades de los estimadores



www.unir.net